

基于数据重上传的通用量子分类器复现

理论分析与数值实验

崔正平, 张译夫, 张扬皓

课程大作业汇报

核心问题与基本思想

理论部分·崔正平

核心问题

- 如何把经典输入 $\mathbf{x}$ 编码进量子电路, 并通过测量输出类别?
- 如果只编码一次数据, 后续固定旋转对所有输入作用相同, 难以形成复杂决策边界.
- 我们希望在量子比特数很少时仍获得足够的非线性表达能力.

数据重上传思想

- 在每一层重新读取同一个输入.
- 各层使用可训练的数据权重与旋转偏置.
- 多层旋转逐步形成输入依赖的量子态.

$$|0\rangle \xrightarrow{L_1} \dots \xrightarrow{L_N} |\psi(\mathbf{x})\rangle \longrightarrow \hat{c}.$$

用多次数据编码提高少量量子比特的分类表达能力.

Source: Pérez-Salinas et al., Quantum 4, 226 (2020).

理论基础: 量子态, Bloch 球与保真度

理论部分·崔正平

量子态的 Bloch 表示

$$\rho = \frac{1}{2} (I + \mathbf{r} \cdot \boldsymbol{\sigma}), \quad r_i = \text{tr}(\rho \sigma_i).$$

- $\boldsymbol{\sigma} = (\sigma_x, \sigma_y, \sigma_z)$ 是 Pauli 矩阵组.
- $\mathbf{r}$ 是 Bloch 向量; 纯态满足 $|\mathbf{r}| = 1$, 混合态满足 $|\mathbf{r}| < 1$.

分类的几何解释

$$F_c(\mathbf{x}) = \text{tr}[\rho_c \rho(\mathbf{x})] = \frac{1 + \mathbf{s}_c \cdot \mathbf{r}(\mathbf{x})}{2}.$$

- 最大化 F_c 就是让输出方向接近第 c 类标签方向 $\mathbf{s}_c$.
- 二分类使用相反方向; 四分类使用正四面体顶点.
- 最终预测为 $\hat{c} = \arg \max_c F_c(\mathbf{x})$.

第 i 层先将数据和可训练参数组成旋转角, 再施加单量子比特旋转:

$$\phi_i(\mathbf{x}) = \theta_i + \mathbf{w}_i \circ \mathbf{x}, \quad L_i(\mathbf{x}) = U(\phi_i(\mathbf{x})).$$

$$|0\rangle \xrightarrow{U(\phi_1)} \dots \xrightarrow{U(\phi_N)} |\psi(\mathbf{x})\rangle \xrightarrow{F_c(\mathbf{x})} \hat{c}.$$

- ① **编码:** $\mathbf{w}_i$ 缩放输入, θ_i 提供可训练偏置.
- ② **演化:** 同一输入经过 N 次重上传, 得到输出态 $|\psi(\mathbf{x})\rangle$.
- ③ **测量:** 计算输出态与各类别标签态的保真度 $F_c(\mathbf{x})$.
- ④ **更新:** 经典优化器根据训练损失更新 θ_i , $\mathbf{w}_i$ 及类别权重.

为什么能够产生非线性

- 旋转轴之间通常不对易, 因而各层不能简单合并.
- 多层乘积产生交叉项及不同频率的三角函数组合.
- 增加重上传层通常提高表达能力, 但也会增加优化难度.

如何训练

$$\chi_f^2 = \sum_{\mu} [1 - F_{s_{\mu}}(\mathbf{x}_{\mu})]^2.$$

$$\min_{\mathbf{p}} \chi^2(\mathbf{p}), \quad \ell_j \leq p_j \leq u_j.$$

- $\mathbf{p}$ 汇总旋转参数, 数据权重和类别权重.
- L-BFGS-B 用有限组历史向量近似逆 Hessian, 无需存储完整矩阵.

实验 1-3 依次检验损失, 电路结构与剪枝

第一组实验·张扬皓

统一任务与配置

- 圆形二分类:

$$x_1^2 + x_2^2 < \frac{2}{\pi}.$$

- 训练/测试样本数:
200/4000.
- 五个参数初始化随机种子.
- Python 状态向量模拟,
L-BFGS-B 优化.

三个问题

- ① 重叠模损失与保真度损失是否等价?
- ② 减少层数, 增加量子比特或加入 CZ 能否保持性能?
- ③ 删除一个完整的重上传层能否真正降低资源消耗?

实验 1-3: 改变目标或结构都会影响性能


第一组实验·张扬皓

- **实验 1: 损失函数.** 相同初值下, 重叠模损失与保真度损失的平均准确率分别为 0.88 和 0.84. 两者对应不同优化目标, 不能直接互换.
- **实验 2: 电路结构.** 1Q-L4 基准准确率为 0.84; 1Q-L2, 2Q-L2 无纠缠和 2Q-L2 CZ 分别为 0.79, 0.52 和 0.60, 均未保持基准性能.
- **实验 3: 层剪枝.** L4 $\rightarrow$ L3 后准确率由 0.84 降至 0.82; 未优化线路深度由 20 降至 15, 但优化编译后的深度仍为 5.

减少参数或增加量子比特, 都不会自动转化为精度与编译资源收益.

实验 4: 大多数样本在 128 shots 后即可停止

第一组实验·张扬皓



准确率与平均 shots

模型	准确率	shots
L4	0.82 ± 0.03	315.2
剪枝 L3	0.81 ± 0.02	329.8

- 与固定 2048 shots 的准确率差小于 0.005.
- 平均测量成本减少约 84%.
- 结果来自理想有限测量模拟.

第二组实验在五类任务上系统扫描配置


第二组实验·张译夫

五类分类任务

- 非凸边界
- 二分类圆环
- 三维球
- 四分类方块
- 四分类波浪线

配置网格


- 层数: 1, 2, 3, 4, 5, 6, 8, 10.
- 非加权/加权保真度损失.
- 1/2/4 量子比特, 有/无 CZ.
- 合计 $5 \times 61 = 305$ 次训练.



非凸边界示例: 左侧为数据标签, 右侧为模型预测区域.

层数带来最稳定增益, 其他因素依赖具体任务


第二组实验·张译夫




- 平均性能主要在前 5-6 层提升, 随后进入平台区.
- 在 115 对共享配置上, 加权损失平均提高 6.34 个百分点, 但并非每类任务都占优.
- 在 105 对纠缠比较中, CZ 的平均增益仅为 0.53 个百分点且正负并存.

一个典型案例: CZ 将圆环准确率提高到 96%

第二组实验·张译夫



无 CZ: 70.45%



加入 CZ: 96.00%

- 两者均为 4 量子比特, 2 层, 加权保真度模型, 只改变是否加入纠缠门.
- 这是纠缠收益最大的实例; 在全部 105 对比较中, CZ 的平均增益仅为 0.53 个百分点, 因而不能推广为普遍结论.

五类任务的最佳准确率均超过 93%

第二组实验·张译夫

任务	最高准确率	损失	量子比特	CZ	层数
非凸边界	97.75%	χ_{wf}^2	2	无	8
二分类圆环	97.25%	χ_{wf}^2	2	无	5
三维球	96.17%	χ_{wf}^2	4	有	2
四分类方块	98.58%	χ_f^2	2	有	5
四分类波浪线	93.90%	χ_{wf}^2	4	有	8

- 最优电路横跨 2/4 量子比特, 2-8 层及有/无 CZ, 不存在统一最优结构.
- 上表是从 305 个配置中按固定测试集准确率选出的描述性结果, 仍需验证集选择和多随机种子复核.

结论: 数据重上传有效, 资源收益仍需任务化验证

总结·张译夫

- 多次输入编码与非对易旋转产生丰富的三角函数组合, 使少量量子比特能够表示复杂决策边界.
- 重上传层数是最稳定的容量来源; 加权保真度和纠缠结构的收益具有明显任务依赖性.
- 简单删层或增加量子比特不会自动带来更好的精度或更浅的编译电路;
- 当前结果来自理想状态向量模拟, 随机种子数量有限, 尚未包含设备噪声, 真机实验和统一经典基线.

谢谢!